

Análise de Desempenho e Quantização do ModernBERTBr

Anderson Barbosa Soares

¹Departamento de Computação – Universidade Federal de São Carlos (UFSCar)

anderson.soares@estudante.ufscar.br

Resumo. *Análise do impacto da redução de precisão numérica no modelo ModernBERTBr em tarefas de similaridade semântica (STS) e inferência lógica (RTE) em português. Utilizando uma GPU NVIDIA RTX 5070, foram testados formatos de alta precisão (FP32, FP16, BF16) e versões quantizadas (8 e 4 bits). Os resultados demonstram que o uso de BF16 e 4 bits reduz o consumo de VRAM em 50% e otimiza a latência sem comprometer a acurácia, que se manteve em 83,91% no RTE. Conclui-se que a quantização é uma técnica eficaz para viabilizar modelos de linguagem robustos em hardwares limitados.*

1. Introdução

A introdução do Transformer em 2017, com seu mecanismo de self-attention, representou um avanço significativo nos modelos de linguagem, impulsionando o desempenho em tarefas como compreensão de texto, tradução automática e classificação [Vaswani et al. 2017]. Entretanto, esse mecanismo elevou os requisitos computacionais, tornando modelos maiores caros e desafiadores de serem executados em hardware com recursos limitados.

Apesar disso, a pesquisa continua avançando os Transformers para aprimorar desempenho e precisão. Nesse contexto, surge o ModernBERT (evolução do BERT original), que incorpora inovações arquiteturais e apresenta melhorias em velocidade, uso de memória e resultados em tarefas de classificação [Warner et al. 2025]. Com base nessa arquitetura, foi desenvolvido o ModBERTBr (ModernBERT-BR), adaptado especificamente para o português brasileiro, o que permite criar modelos locais mais robustos para tarefas de PLN em português [Wu and Garcia 2025]. Embora essas melhorias sejam significativas, o tamanho dos modelos ainda limita seu uso em sistemas menos robustos. Assim, técnicas de otimização como quantização (redução de precisão numérica para INT8/INT4) são imprescindíveis para diminuir tempo de inferência e consumo de memória, preservando acurácia.

Dessa forma, este trabalho busca analisar o desempenho do ModBERTBr durante a sua execução nas tarefas de STS (Similaridade de Sentenças) e RTE (Inferência Lógica), ao alterar a sua representação numérica original. Para isso, são consideradas diferentes estratégias de precisão e quantização, variando desde formatos de alta precisão até compressões com poucos bits. Assim, mostramos que é possível reduzir drasticamente a quantidade de memória e o tempo de inferência sem alterar significativamente a precisão do modelo.

2. Trabalhos Relacionados

O ModernBERT é uma família aberta de modelos encoder-only que combina melhorias arquiteturais como camadas GeGLU, embeddings posicionais RoPE, atenção alternada

local-global e unpadding completo. Além disso, suporta contextos de até 8.192 tokens e supera encoders anteriores como BERT, RoBERTa e DeBERTaV3. Embora apresente grandes avanços, o ModernBERT não é adequado para outros idiomas como o Português, uma vez que foi treinado apenas em inglês [Warner et al. 2025]. Dessa forma, o ModernBERTBr adapta a arquitetura original para o português brasileiro através do treinamento com a base de dados BrWAC, preservando os ganhos de desempenho do ModernBERT para tarefas de processamento de linguagem natural no português [Wu and Garcia 2025].

A quantização pós-treinamento (Post-Training Quantization - PTQ) é uma técnica para reduzir o tamanho de modelos de linguagem sem precisar treiná-lo novamente, composta por duas abordagens: a quantização dinâmica em que o processo de quantização ocorre durante a execução do modelo após cada ativação e a quantização estática em que os parâmetros de quantização são calculados antes da execução [Lang et al. 2024]. Em [Dettmers et al. 2022], apenas uma pequena parte das dimensões do modelo com valores elevados é mantida em 16 bits enquanto o restante é reduzida para 8 bits, o que permite reduzir o uso de memória e tempo de execução do modelo sem afetar muito a precisão. Em [Dettmers et al. 2023] é utilizado o formato NF4 (NormalFloat de 4 bits) através de uma quantização que preserva os pesos do modelo em 4 bits, especialmente quando seguem uma distribuição normal, e convertidos para 16 bits apenas quando computados, o que mantém o desempenho das tarefas enquanto reduz significativamente o uso de memória.

3. Metodologia

Inicialmente, foi utilizado o modelo ModernBERTBr e aplicou-se a técnica de fine-tuning. Todo o treinamento seguiu as recomendações técnicas apresentadas em [Wu and Garcia 2025], utilizando o formato de alta precisão BF16 e uma configuração fixa de semente aleatória (seed 42) para garantir a reprodutibilidade. Após isso, foi realizada a redução da resolução numérica do modelo onde foram testados cinco formatos de representação: os modelos de alta precisão (Float32, Float16 e BF16) e as versões quantizadas de 8 bits e 4 bits.

Os experimentos foram executados em um ambiente de alto desempenho equipado com uma GPU NVIDIA RTX 5070, que possui 12 GB de VRAM GDDR7, operando com suporte ao CUDA 13.0. O sistema contou com um processador Intel Xeon® E5-2673 v4 e 64.5 GB de memória RAM DDR4. A fim de garantir a estabilidade dos dados, cada teste foi precedido por rodadas de aquecimento da GPU (warmup) e repetido dez vezes. Esse procedimento é essencial para preparar a memória da placa de vídeo antes de validar as representações. Além disso, o volume de dados processados por vez (batch size) foi fixado em 62, uma estratégia definida para forçar o uso da GPU e evidenciar as diferenças de desempenho entre as representações.

4. Resultados

Os resultados apresentados na Tabela 1 revelam o equilíbrio entre a precisão das predições e a eficiência de hardware do modelo *ModernBERTBr*. Ao analisar a tarefa de similaridade semântica (STS), observa-se que a redução da precisão de **Float32** para **Float16** e **bfloat16** reduziu o uso de memória VRAM em aproximadamente 50%, decrescendo de 0,66 GB para 0,33 GB, enquanto a latência de processamento foi otimizada de 0,98 ms para cerca de 0,58 ms. Além disso, essa redução de recursos não comprometeu a qualidade do modelo, uma vez que o coeficiente de Pearson permaneceu estável em 0,7924. A

versão quantizada em 4 bits (**BnB 4bit**), o modelo atingiu sua pontuação mais alta de Pearson (0,7945), indicando que a compressão dos pesos pode, em certos cenários, favorecer a generalização.

Na tarefa de implicação textual (RTE), a estabilidade se manteve. A acurácia apresentou uma variação mínima, partindo de 84,03% nas precisões mais altas e mantendo-se em 83,91% mesmo na configuração mais leve de 4 bits. Os formatos de 16 bits (FP16 e bfloat16) mostraram-se os mais velozes na GPU. Em contrapartida, as versões de 8 bits apresentaram uma latência superior (2,87 ms), o que se justifica pelo esforço adicional de processamento necessário para a desquantização dos dados durante a execução.

Dessa forma, os dados evidenciam que a utilização de formatos como o **bfloat16** e o **4 bits** oferece uma excelente relação de custo-benefício. Enquanto o primeiro maximiza a velocidade de resposta, o segundo permite a execução do modelo com uma ocupação de memória reduzida, mantendo o desempenho em métricas de acerto (F1 Macro de 0,83) similar ao do modelo original, demonstrando a viabilidade de implantar modelos de linguagem modernos em ambientes com diferentes restrições de hardware sem perda significativa de precisão.

Tabela 1. Resultados das tarefas STS e RTE em performance e eficiência de hardware

Representação	STS (ASSIN 2)				RTE (ASSIN 2)			
	Pearson	MSE	VRAM (GB)	Lat. (ms)	Acc (%)	F1 Macro	VRAM (GB)	Lat. (ms)
FP32	0.7924	0.5355	0.6641	0.9884	84.03	0.8385	0.6651	0.9908
FP16	0.7924	0.5359	0.3344	0.5883	84.03	0.8385	0.3353	0.5925
bfloat16	0.7921	0.5316	0.3344	0.5905	84.03	0.8385	0.2721	0.9364
8bit	0.7922	0.5242	0.2778	2.8789	83.99	0.8381	0.2788	2.8272
4bit	0.7945	0.6143	0.3060	1.0941	83.91	0.8372	0.2721	0.9364

5. Conclusão

O presente trabalho demonstrou que a aplicação de técnicas de quantização no modelo *ModernBERTBr* permite uma redução significativa no consumo de recursos computacionais sem diminuir a precisão em tarefas de Processamento de Linguagem Natural para o português brasileiro. Os resultados revelam que o uso de precisões reduzidas, como o **bfloat16**, é capaz de otimizar a latência e o uso de VRAM em cerca de 50%, enquanto a compressão para **4 bits** possibilita a execução do modelo em ambientes de hardware limitado com perdas mínimas de acurácia. Como trabalho futuro, pretende-se abordar a implementação de técnicas de quantização estática, bem como adicionar novas métricas.

Referências

- Dettmers, T., Lewis, M., Belkada, Y., and Zettlemoyer, L. (2022). Gpt3. int8 (): 8-bit matrix multiplication for transformers at scale. *Advances in neural information processing systems*, 35:30318–30332.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized llms. *Advances in neural information processing systems*, 36:10088–10115.
- Lang, J., Guo, Z., and Huang, S. (2024). A comprehensive study on quantization techniques for large language models. In *2024 4th International conference on artificial intelligence, robotics, and communication (ICAIRC)*, pages 224–231. IEEE.

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- Warner, B., Chaffin, A., Clavié, B., Weller, O., Hallström, O., Taghadouini, S., Gallagher, A., Biswas, R., Ladhak, F., Aarsen, T., et al. (2025). Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2526–2547.
- Wu, W. B. T. L. and Garcia, L. P. F. (2025). Modbertbr: A modernbert-based model for brazilian portuguese. In *Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)*, pages 2044–2055. SBC.