

Uso de Rede Neural Convolucional na Classificação de Câncer Colorretal

João Gabriel Rigo Alves¹

¹Universidade Federal do Pampa (Unipampa)
Av. Maria Anunciação Gomes Godoy, 1650, Bagé – RS – Brasil

Resumo. Este artigo apresenta uma Rede Neural Convolucional (CNN) para classificação automática de tecidos de câncer colorretal em imagens histopatológicas. O modelo foi treinado com 5.000 imagens RGB (150×150 px), distribuídas em oito classes, com divisão de 70% para treino, 10% validação e 20% teste. A arquitetura utiliza três blocos convolucionais seguidos de camadas densas e saída Softmax. O treinamento foi realizado com TensorFlow/Keras no Google Colab, utilizando o otimizador Adam e técnicas como EarlyStopping. O modelo atingiu acurácia de 95,25% no treino, 92,0% na validação e 94,3% no teste, indicando bom desempenho e capacidade de generalização na classificação multiclasse.

Câncer Colorretal; Imagens Histopatológicas; Redes Neurais Convolucionais; Aprendizado Profundo.

1. Introdução

O câncer colorretal é uma das neoplasias mais incidentes globalmente e figura entre as principais causas de morte por câncer. O diagnóstico definitivo é feito via análise histopatológica de lâminas, um processo especializado sujeito a alta variabilidade interobservador [4]. Métodos de inteligência artificial, especialmente redes neurais profundas, têm mostrado potencial para melhorar a objetividade e eficiência em diagnósticos de imagens médicas [2, 3].

Este trabalho propõe uma CNN para classificação multiclasse de tecidos colorretais. Usamos a base pública de Kather et al. (2016) [1], que contém 5.000 imagens (150×150 px) de oito tipos teciduais. O objetivo é treinar um modelo end-to-end que distinga essas classes com alta precisão, fornecendo suporte ao diagnóstico automatizado do câncer colorretal.

2. Trabalhos Relacionados

Kather et al. (2016) introduziram o conjunto de imagens colorretais e demonstraram classificação multiclasse com acurácia de 87–94% usando SVM com descritores de textura [1]. Revisões recentes mostram o sucesso do deep learning em imagens médicas: Litjens et al. (2017) [2] descrevem CNNs como estado da arte em várias tarefas; Esteva et al. (2017) [3] alcançaram acurácia “nível dermatologista” em classificação de pele. Esses resultados motivam nossa abordagem end-to-end sem extração manual de características.

3. Metodologia

3.1. Base de Dados e Pré-processamento

Utilizamos a base *Colorectal Histology* de Kather et al. (2016) [1]. Contém 5.000 imagens RGB (150×150 px) de tecido colorretal, distribuídas em oito classes: epitélio tumoral, estroma simples, estroma complexo, células imunológicas, resíduo/muco, glândulas mucosas, tecido adiposo e fundo. Os dados foram divididos estratificadamente em 70% para treinamento, 10% para validação e 20% para teste, mantendo a proporção de cada classe.

3.2. Arquitetura da Rede Neural

A CNN proposta possui três blocos convolucionais sequenciais: primeiro bloco com 32 filtros 3×3 (ReLU, padding *same*), BatchNorm, MaxPool 2×2 e Dropout (0,25); segundo bloco com 64 filtros 3×3 (ReLU), BatchNorm, MaxPool 2×2 e Dropout (0,25); terceiro bloco com 128 filtros 3×3 (ReLU), BatchNorm, MaxPool 2×2 e Dropout (0,25). Após esses blocos, aplica-se Global Average Pooling. Em seguida, há duas camadas densas (256 e 128 neurônios, ReLU) com Dropout (0,5). A saída é softmax com 8 neurônios. O modelo principal tem 1.065.722 parâmetros treináveis.

3.3. Treinamento e Implementação

Implementamos em Python usando TensorFlow/Keras. O treinamento foi realizado no Google Colab com GPU NVIDIA Tesla T4. Normalizamos as imagens ([0,1]) e usamos o otimizador Adam (LR=0,001), batch size 32, e 30 épocas. Aplicamos EarlyStopping (paciência 5) e ReduceLROnPlateau (fator 0,5, paciência 3) para evitar overfitting. A métrica principal foi acurácia, e a perda foi categorical crossentropy.

4. Resultados e Discussão

O modelo apresentou acurácia de 95,25% no conjunto de treino, 92,0% na validação e 94,3% no teste. Esses resultados indicam que a CNN foi capaz de aprender padrões relevantes nas imagens histopatológicas, mantendo bom desempenho em dados não vistos.

A diferença moderada entre treino e validação sugere leve overfitting, porém controlado, indicando boa capacidade de generalização. A acurácia de teste próxima à de treino reforça a consistência do modelo.

A utilização de técnicas como EarlyStopping, Dropout e Batch Normalization contribuiu para a estabilidade do treinamento e redução do sobreajuste.

A Figura 1 apresenta a matriz de confusão do modelo.




Figura 1. Matriz de confusão do modelo CNN no conjunto de validação.

Tabela 1. Métricas médias de desempenho do modelo.

Métrica	Valor (%)
Acurácia (validação)	92,0
Precisão média	94,4
Recall médio	94,5
F1-score médio	94,4

5. Conclusão

O trabalho mostrou a viabilidade de CNNs na classificação automatizada de tecidos colorretais. A CNN treinada atingiu acurácia de 92,0% na validação e 94,3% no teste, indicando boa capacidade de generalização do modelo.

- Demonstração da capacidade das CNNs em aprender padrões histológicos complexos;
- Pipeline reprodutível;
- Potencial de apoio ao diagnóstico médico.

Referências

- [1] Kather, J.N. et al. Multi-class texture analysis in colorectal cancer histology. Scientific Reports, 2016.
- [2] Litjens, G. et al. A survey on deep learning in medical image analysis. Medical Image Analysis, 2017.
- [3] Esteva, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. Nature, 2017.
- [4] Elmore, J.G. et al. Diagnostic concordance among pathologists. JAMA, 2015.